

Introducción a los Sistemas RAG

¿Qué es RAG?

RAG significa Retrieval Augmented Generation. Es una técnica que combina recuperación de información y generación de texto utilizando modelos de lenguaje.

Funcionamiento general

El pipeline RAG primero recupera información relevante desde una base de datos vectorial y luego utiliza un modelo de lenguaje para generar una respuesta basada en el contexto recuperado.

Embeddings

Los embeddings son representaciones numéricas del texto. Permiten comparar similitud semántica entre fragmentos de información y consultas del usuario.

Chunking

El chunking divide documentos largos en fragmentos más pequeños llamados chunks. Esto mejora la recuperación de contexto relevante.

ChromaDB

ChromaDB es una base de datos vectorial utilizada para almacenar embeddings y recuperar chunks relevantes durante las consultas.

LLM

El modelo de lenguaje o LLM utiliza el contexto recuperado para generar respuestas coherentes y fundamentadas.

Flujo del pipeline

El flujo típico consiste en cargar documentos PDF, dividirlos en chunks, generar embeddings, almacenar vectores en ChromaDB, recuperar contexto relevante y finalmente generar respuestas con el LLM.

Ventajas de RAG

RAG permite reducir alucinaciones, mejorar la precisión de respuestas y utilizar información actualizada sin necesidad de reentrenar el modelo.